数据可视化技术

数据可视化基础

叶志鹏

南京理工大学泰州科技学院

1st Jan, 2023

定义

数据可视化是以图表或图形呈现数据。让用户可以直观方式观察数据、分析数据，为数据挖掘做铺垫。[Ama23]

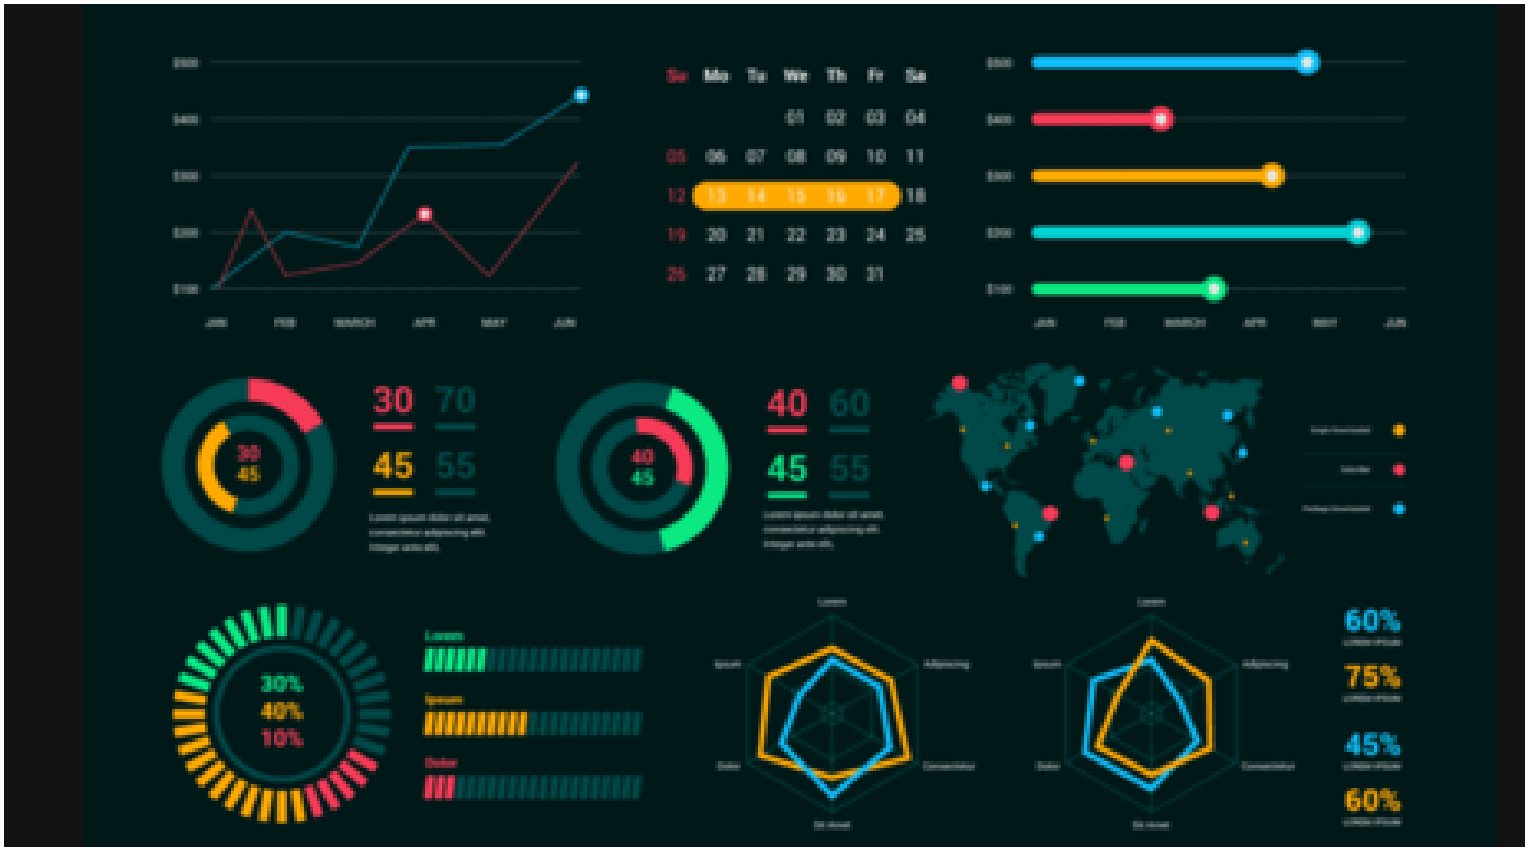

例子

三个班的数字图像处理期末成绩的数据分析与可视化。

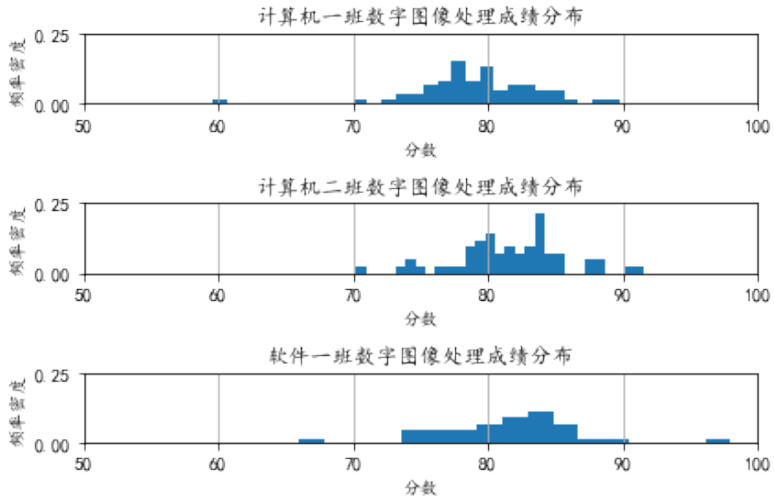

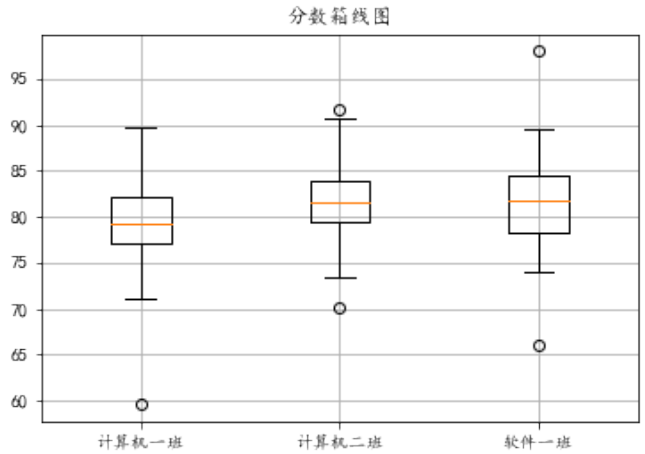

日常摄影

图 1: 泰州银杏树

图 2: 泰州城

商业领域

图 3: 淘宝双 11 销量可视化

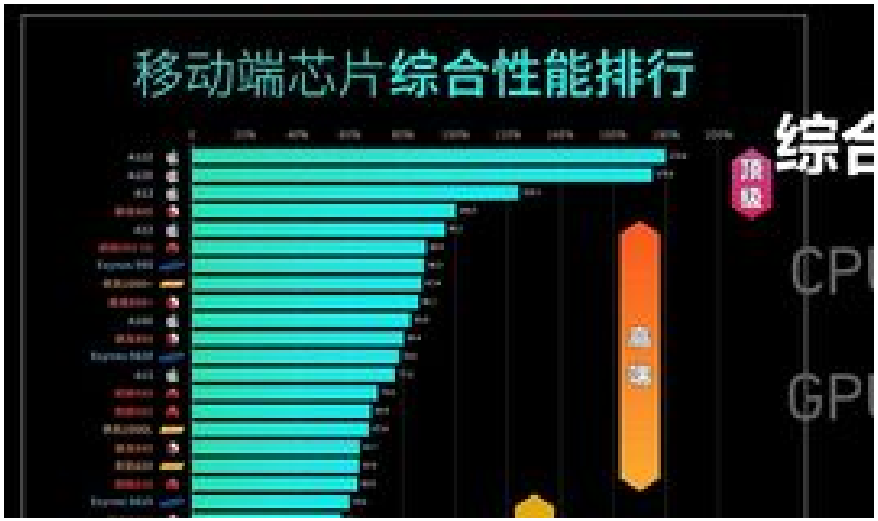

图 4: 手机性能排行榜条形图

疫情可视化

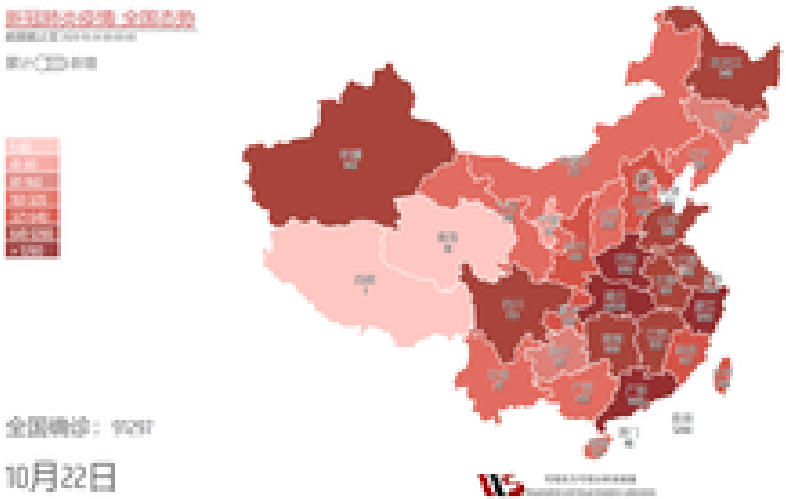

图 5: 清华疫情数据可视化网站

图 6: 各国新冠确诊病例条形图

医学领域

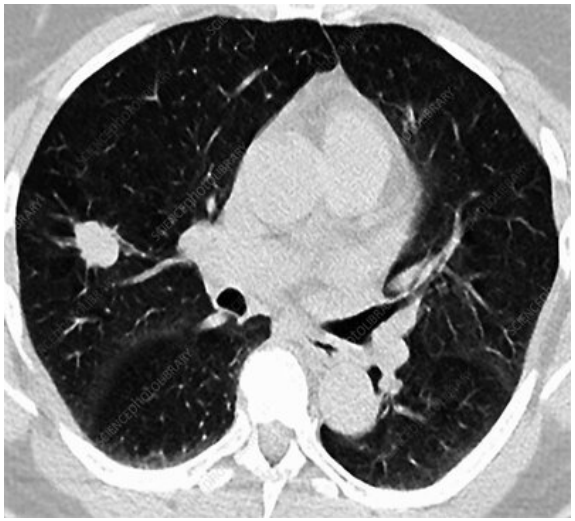

图 7: 肺部 CT computer tomography

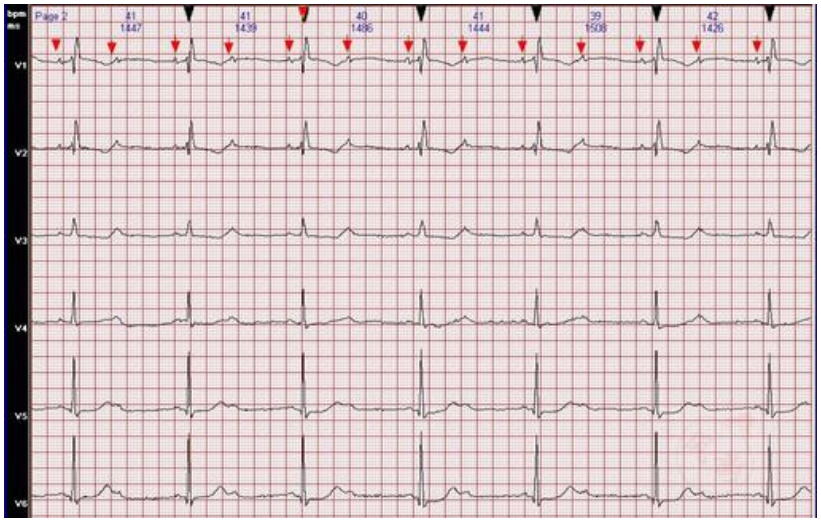

图 8: 心电图

气象与地理领域

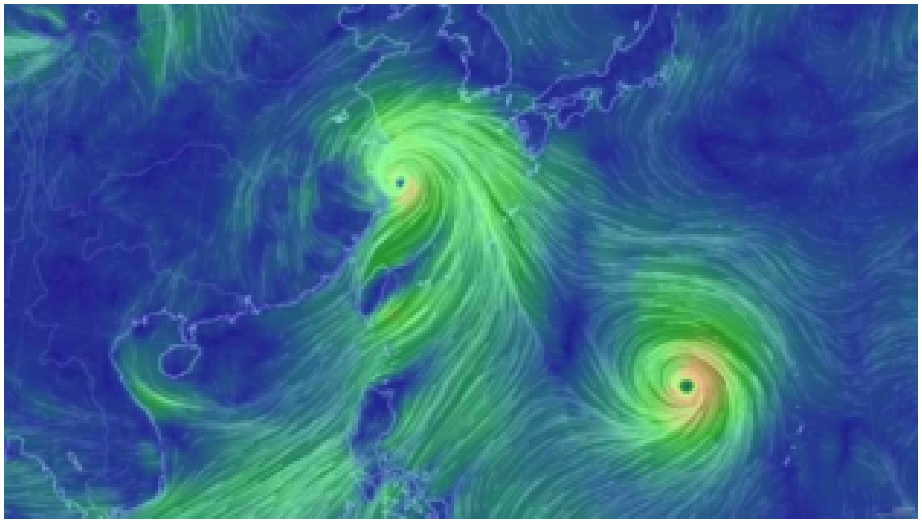

图 9: 风场

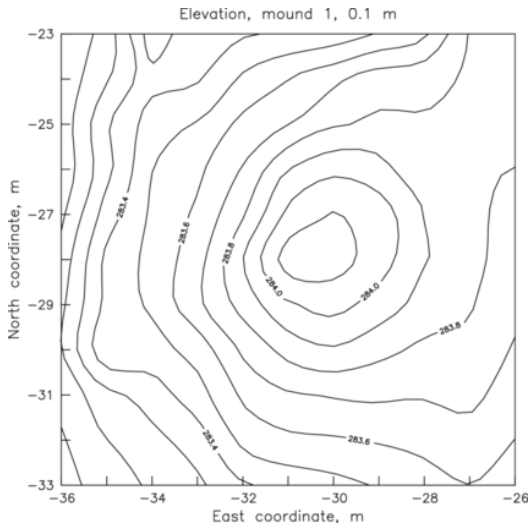

图 10: 等高线图

天文图像领域

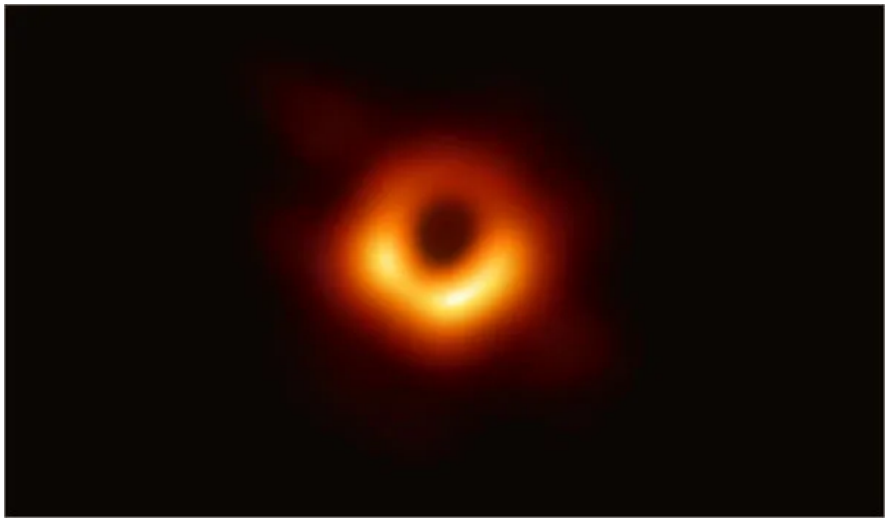

图 11: 黑洞可视化 [BJZ+16]

图 12: 太空图片

文本数据的可视化

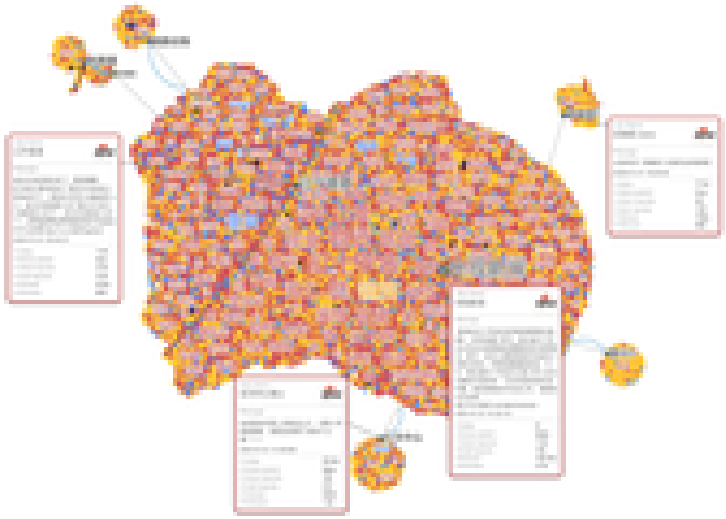

图 13: 词云

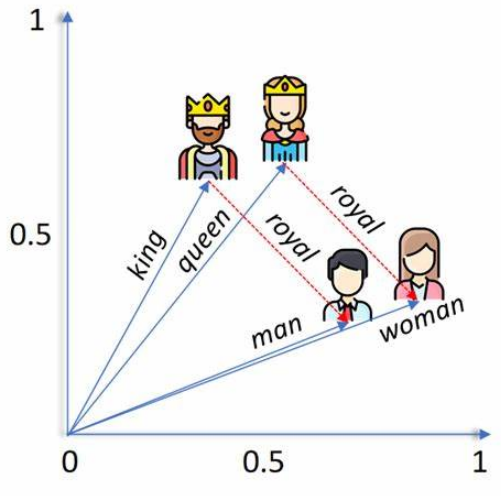

图 14: Word Embedding 可视化

数据可视化的应用场景

数据可视化还有哪些应用场景？

常用软件或工具介绍

软件	学习难度	灵活性	商业	代码	面向群体
Excel	容易	差	商业软件	低代码	无编程经验人员
Tableau	中等	中等	商业软件	低代码	数据分析师，产品经理等
Power BI	中等	中等	商业软件	低代码	数据分析师，产品经理等
MATLAB	难	好	商业软件	需要代码	编程经验丰富的专业人员
Matplotlib	难	好	Python 开源库	需要代码	编程经验丰富的专业人员
Streamlit	难	好	Python 开源库	需要代码	编程经验丰富的专业人员

对口职业

图 15: 京东数据分析师

图 16: 智慧牙数据挖掘

连续型数据与离散型数据

- 在统计学中，数据按变量值是否连续可分为连续数据与离散数据两种。
- 离散数据其数值只能用自然数或整数单位计算的数据。如性别，班级，种类，胖瘦等。
- 连续数据在一定区间内可以任意取值。如身高，体重，零件尺寸等。
- 计算机只有离散数据。
- 如何画出连续函数？

连续型数据与离散型数据

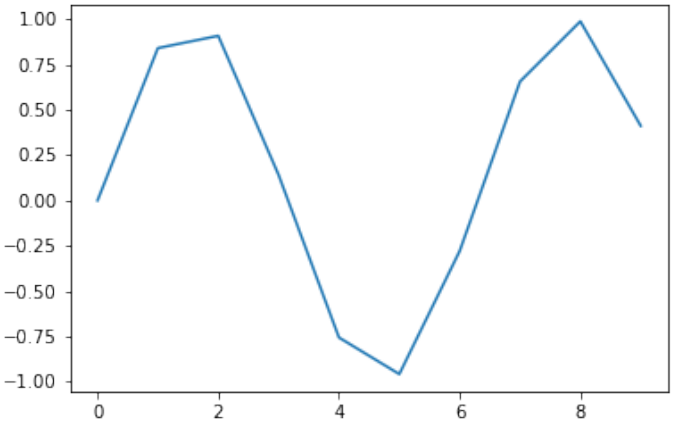

图 17: 采样频率 $1HZ$ 的 $y = sin(x)$ 函数的可视化结果

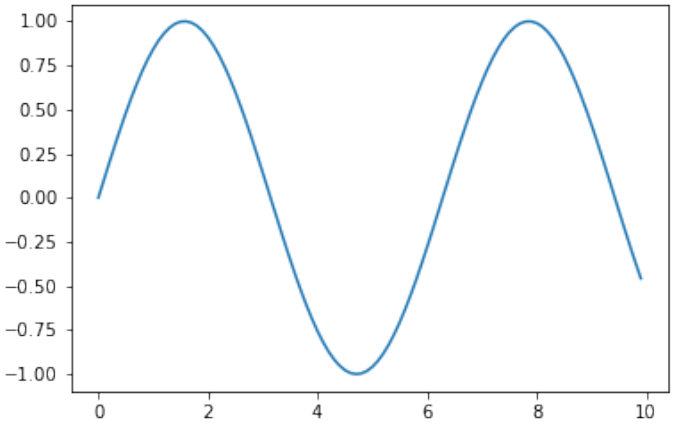

图 18: 采样频率 $2HZ$ 的 $y = sin(x)$ 函数的可视化结果

连续信号在时间（或空间）上以某种方式变化着，而采样过程则是在时间（或空间）上，以 T 为单位间隔来测量连续信号的值。T 称为采样间隔。采样过程产生一系列的数字，称为样本。采样间隔的倒数，1/T 即为采样频率，fs，其单位为样本/秒，即赫兹(hertz)。

结构化数据与非结构化数据

- 结构化数据是高度组织和整齐格式化的数据，可以放入表格和电子表格中的数据类型。如一个班的考试成绩表格，2022年每月销售额表格等。
- 非结构化数据与结构化数据定义相反。如图像，视频，音频，纯文本，HTML 等。
- 对于结构化数据，可视化较为容易呈现图表。对与非结构化数据，如文本数据，需要采用特定的可视化算法（Word Embedding, TF-IDF）进行可视化。

抖音弹幕可视化

图 19: 抖音弹幕可视化

基本数据类型与数据结构

- 基本数据类型有整数、浮点数、字符串、时间戳等
- 数据结构是带有结构特性的数据元素的集合，如数组，队列，链表，树，图，栈，散列表等

内存数据与持久化数据

- 内存的数据是易失性，断电即无
- 硬盘的数据是持久化的，不易丢失

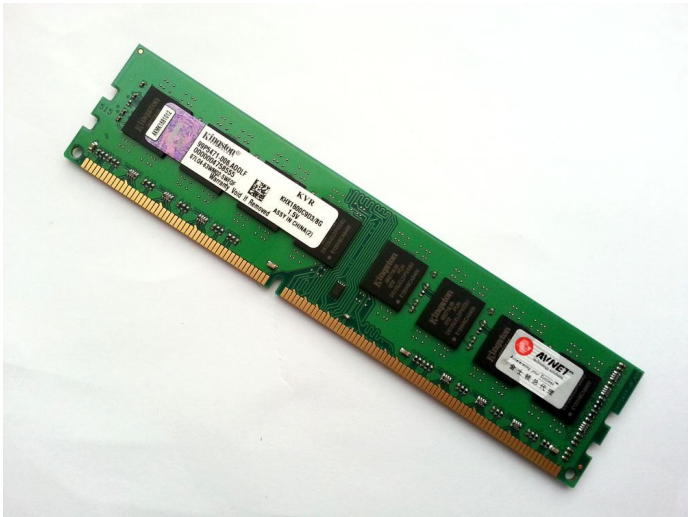

图 20: 内存条

图 21: 硬盘

图表的功能分类

- 用于数据对比的图表包括曲线图，柱状图，条形图，饼状图，堆叠图等

图 22: 支付宝财产配比饼状图

图 23: 中欧医疗健康基金曲线图

数据的相关性 (联系)

- 用于数据相关性的图表包括散点图，热力图，连接图等

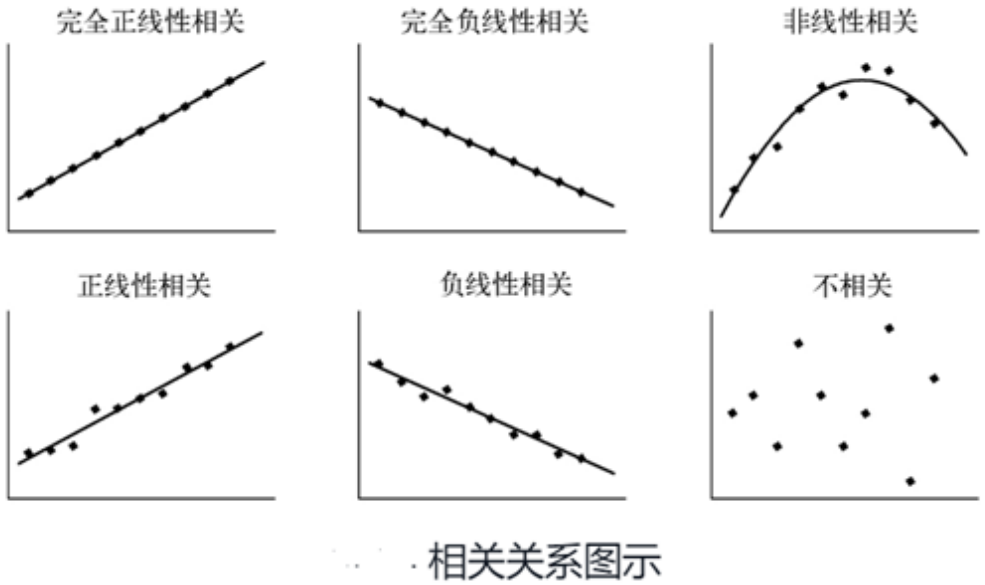

图 24: 散点图与相关性

数据的相关性 (联系)

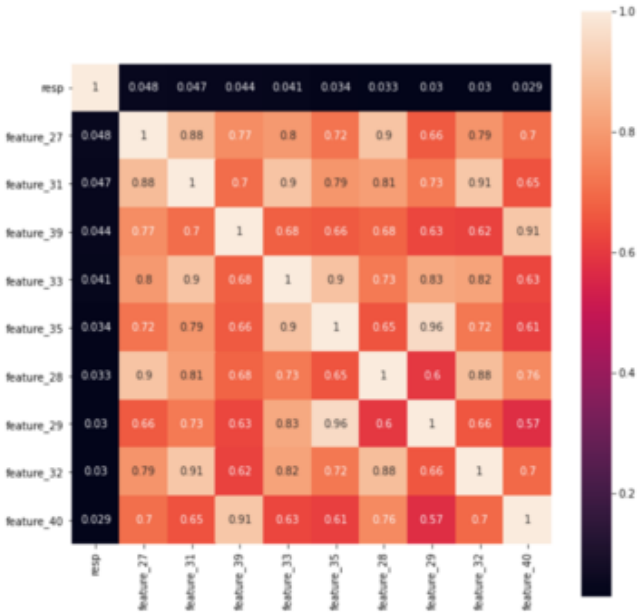

图 25: 相关性热力图

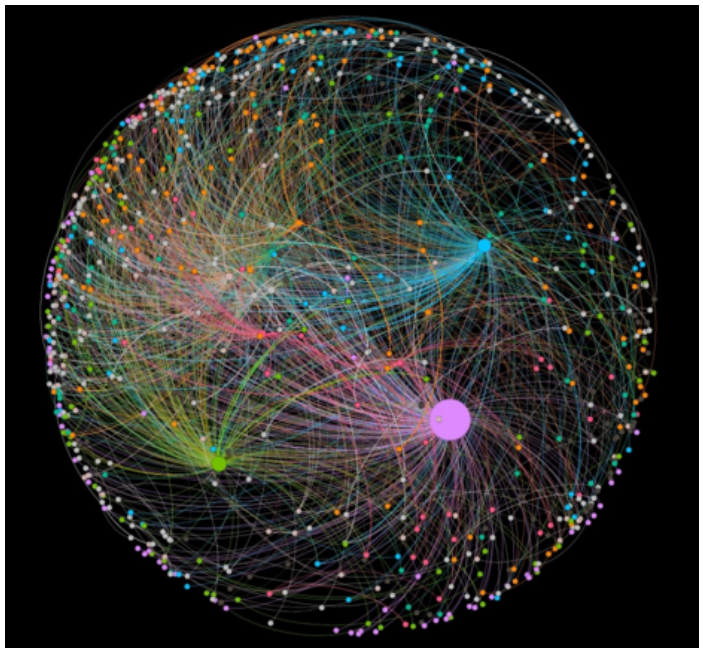

图 26: 节点间的连接关系

数据的结构与分布

- 用于数据结构与分布的图表包括散点图，直方图，箱线图，等高线图，三维图，图像 Image，雷达图，词语。

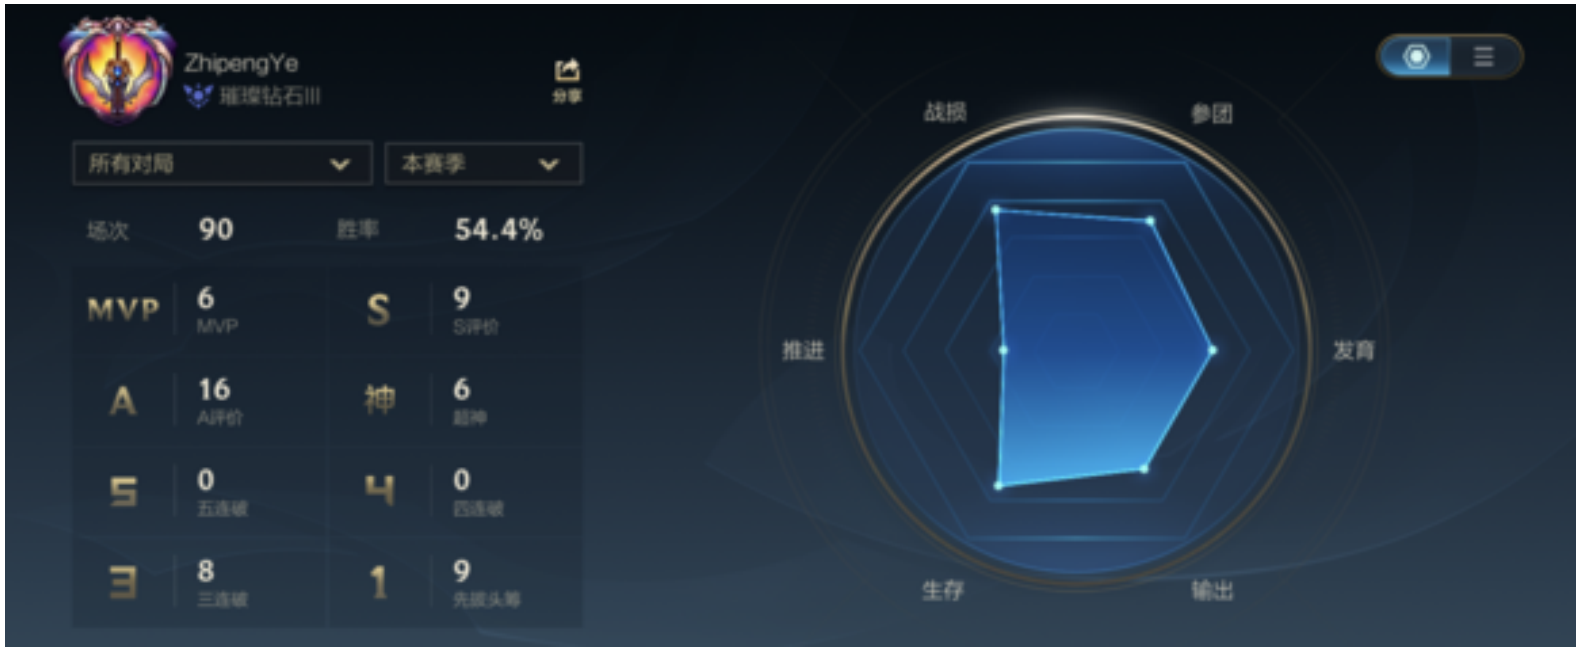

图 27: 英雄联盟游戏人物属性（画像）

数据的结构与分布

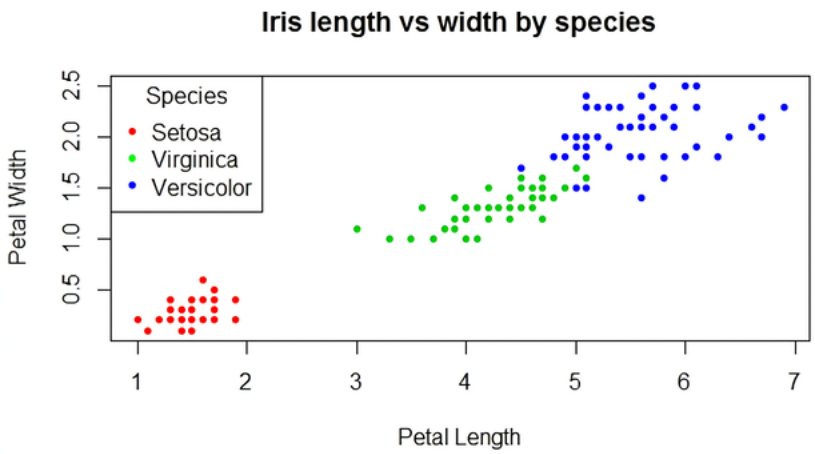

图 28: iris 数据集分布散点图

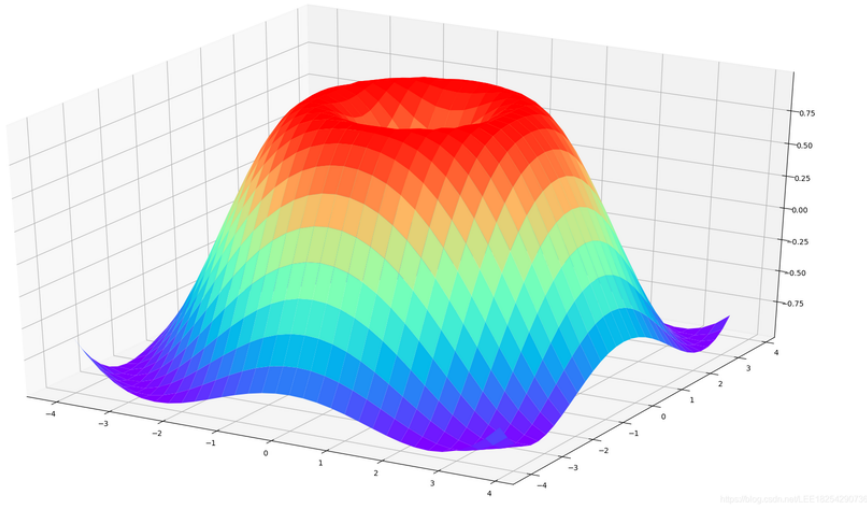

图 29: 三维数据图

静态图表与动态图表

- 相对于静态图表，动态图表更能反应数据的动态变化过程。
- 1949-2020 年中国各省 GDP 动态条形图

单一图表与复合型图表

- 将多个单一图表复合到一个软件界面或者网页，就构成了复合型图表。
- 复合型图表的例子。

数据获取与导入

- 数据可以从开源数据，爬虫，购买，拍摄，算法生成等途径获取。
- 数据导入需要将硬盘上的持久化数据导入到内存中处理，需要编程操作。可以用 Python 原生的 open 函数也可以使用 Pandas、OpenCV 等开源库操作。

数据预处理

针对缺失数据、噪声数据以及数据不一致等问题，进行数据清理。

- 缺失数据处理方式:
  - 忽略（删除）
  - 人工补录
  - 算法自动推导缺失值
- 噪声数据处理方式:
  - 去噪算法
  - 异常点检测
- 数据不一致的处理方式是通过替换的方式。如评级为“1，2，3”，替换成“A，B，C”

数据可视化

- 数据可视化需要借助可视化工具，将处理好的数据送入可视化工具中，借助计算机图形学，数字图像处理等学科的技术进行图像或图表显示。
- 要结合数据特征和数据分析需求选择合适的图表显示。这是本课程需要大家灵活掌握的科学素养。

数据分析

- 通过上一步图表进行数据分析，也可以在分析的过程当中，增加图表，修改图表，以达到数据分析的目的。
- 通过具体的数学、统计学指标，去衡量数据的质量，分析得出结果。

数据挖掘

数据挖掘 (Data Mining) 是从大量的数据中，提取隐藏在其中的，事先不知道的、但潜在有用的信息的过程。数据挖掘包括以下几类任务：

- 回归
- 分类
- 聚类
- 关联分析

参考文献 I

[Ama23] Amazon.
什么是数据可视化？, 2023.

[BJZ+16] Katherine L. Bouman, Michael D. Johnson, Daniel Zoran, Vincent L. Fish, Sheperd S. Doeleman, and William T. Freeman.
Computational imaging for vlbi image reconstruction.
In *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 913–922, 2016.

Thanks!